

Процедурная мета-рефлексия для генеративных языковых моделей

Муляр Александр Евгеньевич — студент 2-го курса, факультет «ИИКС», Национальный исследовательский ядерный университет «МИФИ», Россия, г. Москва; sshmulyar@gmail.com

Соавтор: Душкин Роман Викторович — старший преподаватель кафедры № 22, Национальный исследовательский ядерный университет «МИФИ», Россия, г. Москва

Аннотация

Генеративные языковые модели нередко выдают содержательный ответ при низкой прозрачности выбранной процедуры и условий её переноса на близкие постановки. Предлагается процедурная мета-рефлексия: до вычислений — явная классификация задачи и обоснованный выбор процедуры с отвергнутыми альтернативами; в ходе решения — процедурная аннотация шагов и маркировка точек адаптации; после ответа — ретроспекция применимости и переносимости. На открытом стенде PMR-Bench из десяти прикладных задач в четырёх предметных доменах выполнено парное сравнение целевого промпта со структурированным базовым условием без мета-рефлексии на одних и тех же постановках; качество оценено по четырём десятибалльным шкалам и интегральному показателю. На трёх коммерческих системах разной мощности получен согласованный прирост относительно базы, наиболее выраженный по шкале выявления скрытых зависимостей (Latent Pattern Quality, LPQ). Выводы при заданном объёме выборки носят пилотный характер; обсуждается расширение стенда и независимый контроль оценок.

Ключевые слова: промпт-инженерия, метакогниция, процедурные знания, декларативные знания, генеративные языковые модели, объяснимое рассуждение, оценка качества ответов, парный эксперимент, воспроизводимость метода, прикладные задачи.

Abstract

Large language models often return plausible answers while leaving the chosen procedure and its transfer conditions implicit. We propose procedural meta-reflection: pre-computation justification of the task class and procedure with rejected alternatives;

in-process procedural annotation of steps and adaptation points; post-answer retrospective on applicability and transferability. On the open PMR-Bench of ten applied tasks in four domains we run a paired comparison between the target prompt and a structured baseline without meta-reflection on identical task statements, scoring four ten-point rubrics and an aggregate index. Across three commercial systems we observe a consistent gain over the baseline, largest on latent-structure insight (LPQ). At the current sample size conclusions are pilot-scale; we outline bench expansion and independent evaluation.

Keywords: prompt engineering, metacognition, procedural knowledge, declarative knowledge, large language models, explainable reasoning, response quality evaluation, paired experiment, method reproducibility, applied tasks.

1. Введение

Генеративные языковые модели всё чаще используются там, где недостаточно итогового текста: требуется воспроизводимая методика, проверяемые допущения и ясная логика перехода между этапами работы. В инженерии, управлении, образовании и смежных областях ценится не только ответ, но и понятная «архитектура рассуждения», позволяющая перенести подход на сходный случай и согласовать его с регламентами.

При этом типичный режим «одной инструкции — одного ответа» на сложной процедурной задаче повышает риск поверхностной генерализации и потери проверяемых связей между этапами. Недостаточно наращивать длину цепочки вывода, если не зафиксированы выбор процедуры, отвергнутые альтернативы и границы применимости выбранного пути. Пошаговые схемы развёртывания рассуждения (*Chain-of-Thought*, CoT) [Wei et al., 2022] и ветвящийся поиск по вариантам ответа (*Tree of Thoughts*, ToT) [Yao et al., 2024] частично снимают проблему глубины, но не заменяют явного процедурного слоя.

Рабочие гипотезы пилотного эксперимента сформулированы так: (1) при неизменных текстах постановок целевой промпт с процедурной мета-рефлексией повышает средние значения интегрального показателя I и шкалы LPQ относительно структурированного базового условия без мета-рефлексии; (2) наибольший относительный эффект ожидается по LPQ, поскольку эта ось напрямую отражает выявление скрытой структуры и «точек отказа», которые целевой контракт требует вербализовать. Проверка ограничена объёмом $n = 10$ пар на испытуемую систему; обобщение на совокупность всех прикладных постановок и моделей не заявляется.

Целью настоящего исследования является разработка и пилотная экспериментальная валидация метода процедурной мета-рефлексии: формализовать целевой промпт-контракт, реализовать его в воспроизводимом конвейере и оценить влияние на качество ответов относительно структурированного базового условия без мета-рефлексии. Для достижения цели решаются следующие задачи: систематизировать связь предлагаемой архитектуры с существующими линиями исследований (раздел 2); изложить методологию стенда и метрик (раздел 3); привести количественные результаты парного эксперимента (раздел 4); обсудить интерпретацию, ограничения и направления развития (раздел 5).

Вклад относительно близких линий промптинга состоит в следующем. CoT и ToT наращивают глубину поиска решения, но не обязывают явно сравнивать альтернативные процедуры и фиксировать условия их переноса; метакогнитивный промптинг в распространённых вариантах смещён к мониторингу хода вывода и не дублирует контракт «обоснование процедуры — исполнение с аннотацией — ретроспекция» в терминах блоков C, P, E, R . Открытый стенд PMR-Bench вместе с конвейером *LLM-as-a-Judge* задаёт воспроизводимую операционализацию и парные агрегаты по нескольким коммерческим системам, что облегчает независимое повторение и расширение набора задач без дообучения весов моделей.

2. Связанные работы

Разграничение декларативных и процедурных знаний устойчиво в когнитивной науке [Anderson, 1983]: декларативные знания вербализуются как факты о мире, процедурные нередко остаются частично имплицитными даже у эксперта, что порождает известную асимметрию «умею — трудно объяснить, почему именно так». Для генеративных моделей это переносится на риск «правильного ответа без явной процедуры».

В обработке естественного языка широкое распространение получили пошаговое развёртывание цепи рассуждения (*Chain-of-Thought*, CoT) [Wei et al., 2022] и ветвящийся поиск по вариантам ответа (*Tree of Thoughts*, ToT) [Yao et al., 2024]. Эти приёмы систематически улучшают качество на многошаговых задачах, однако не требуют по определению явного обоснования выбора процедуры и условий её замены.

Параллельно развивается метакогнитивный промптинг (*Metacognitive Prompting*) [Flavell, 1979], [Wang & Zhao, 2024]: модель вовлекается в мониторинг и самооценку хода рассуждения. В типичных постановках акцент смещён к уверенности и корректности вывода, тогда как процедурная мета-рефлексия адресует именно архитектуру выбранной процедуры как объект отдельного рассуждения.

В монографии Душкина *Метакогнитивная промпт-инженерия* [Душкин, 2025] процедурная мета-рефлексия (*Procedural Meta-Reflection*) встроена в многоуровневую многоагентную декомпозицию рассуждения о промпте: различные роли (в терминологии источника — административный, аналитический, критический и др. уровни) последовательно эксплицируют допущения, контролируют перенос и фиксируют критические точки, а *Procedural Meta-Reflection* требует явной связи этого аналитико-критического контура с выдаваемым артефактом — не только с общими намерениями.

Настоящая статья свёртывает описанный в [Душкин, 2025] многоагентный разбор в одноходовую постановку «один запрос — один структурированный ответ»: открытый стенд PMR-Bench из десяти задач и парное сравнение с базовым условием. Полноформатные многоходовые диалоговые сценарии монографии здесь не воспроизводятся; вместо этого три фазы генерации (до, в процессе, после ответа) компактно кодируют функции, которые в канонической постановке распределены между ролями и раундами: фаза обоснования процедуры соответствует аналитико-критическому выбору метода, фаза исполнения — выдаче результата с процедурной маркировкой шагов, фаза ретроспекции — пост-фактум фиксации переносимости и ограничений.

От привычной структурированной декомпозиции промпта или многоэтапных схем оценки предлагаемая схема отличается тем, что задаёт явный контракт инструкции «обоснование процедуры — исполнение с комментарием — ретроспекция» и совместима с открытым стендом PMR-Bench без дообучения параметров модели.

3. Методология

3.1. Архитектура взаимодействия (операциональное описание техники)

Пусть T — текст постановки задачи (вход), M — генеративная языковая модель с зафиксированной инструкцией π (целевой или базовый вариант). В целевом условии ответ модели представим как кортеж структурных компонентов

$$\mathcal{M}(T; \pi) = \langle C, P, E, R \rangle,$$

где C — классификация задачи и явное объявление типа процедуры (линейная, ветвящаяся, итеративная и т.д.); P — обоснование выбранной процедуры, перечень отвергнутых альтернатив и критерии сравнения; E — пошаговое исполнение с процедурной аннотацией переходов и маркировкой точек, где требуется адаптация входов или допущений; R — ретроспективная оценка уместности процедуры, условий оптимальности и переносимости на близкие постановки. В базовом условии $\pi^{(0)}$ тот же M выдаёт связный текст решения без обязательного разбиения на $\langle C, P, E, R \rangle$ и без требования сравнивать альтернативные процедуры.

Три фазы промпта π взаимно однозначно сопоставляются с блоками кортежа: *до решения* — генерация (C, P) ; *в процессе* — наращивание E ; *после решения* — генерация R . Техника относится к метакогнитивным стратегиям и отличается от смежных приёмов (*Chain-of-Thought* (CoT) [Wei et al., 2022]; *Tree of Thoughts* (ToT) [Yao et al., 2024]) фокусом на обосновании выбора процедуры, а не только на длине цепочки вывода.

3.2. Датасет и условия эксперимента

Число задач $n = 10$ и число предметных доменов (четыре) выбраны как пилотный компромисс между покрытием типовых прикладных контекстов и стоимостью прогонов: десять постановок позволяют удержать парный дизайн на уровне отдельных кейсов при фиксированном судебском протоколе, а четыре домена (инженерия, управление, образование, психотерапия) задают разнесение по регламентированным, организационным, педагогическим и клинически чувствительным сценариям без претензии на репрезентативную выборку отраслей. План развития — монотонное расширение PMR-Bench, добавление задач внутри доменов и ужесточение статистики (в том числе поправки на множественность при одновременной проверке нескольких шкал) при $n \gg 10$.

Использовался специализированный стенд из десяти задач в четырёх прикладных доменах: инженерия ($n = 3$), управление ($n = 3$), образование ($n = 2$), психотерапия ($n = 2$). В совокупности представлены пять задач промежуточного

и пять повышенного уровня сложности. Постановки содержат конкурирующие процедуры, ветвления и необходимость явно обосновывать стратегию.

Каждая задача решалась парно: одна и та же постановка в целевом и в базовом условии. Такое сопоставление даёт прямое сравнение на одной и той же задаче и ослабляет влияние межзадачной изменчивости результатов.

Порядок прогонов. Для каждой испытуемой системы полный набор из десяти задач сначала выполнялся в целевом режиме (PMR), затем полный набор — в базовом режиме; порядок режимов соответствует конвейеру по умолчанию (pmr,baseline). Перемешивание порядка условий и контрбалансировка (например, АВ/ВА) не применялись, поэтому возможные медленные дрейфы на стороне API или провайдера не отделены статистически от эффекта условия; это ограничение внутренней валидности, запланированное к снятию в расширенных прогонах. Внутри каждого режима задачи шли в фиксированном каноническом порядке идентификаторов PMR-001...PMR-010.

Таблица 1: Испытуемые системы и судейство

Испытуемая система	Судья
Qwen3 235B A22B Inst. 2507 FP8	та же
DeepSeek 3.2	та же
YandexGPT 5.1 Pro	Qwen3 235B

Воспроизводимость оценки. Сопоставление ответа с эталонным текстом и методы семантического частичного совпадения (*partial match*) по векторным представлениям (*embeddings*) не использовались. Баллы выставались протоколом *LLM-as-a-Judge* (модель в роли автоматического судьи) по тексту постановки, ответа модели и краткому списку допустимых инвариантов задачи. Дословные системные инструкции судьи и версия программного средства фиксируются в открытых артефактах прогона. Программное средство для запуска прогонов и автоматического судейства реализовано на языке Python.

Инфраструктура. Исполнители и судья вызывались через облачные API поставщиков; аппаратная конфигурация на стороне провайдера авторами не контролировалась. Для воспроизводимости достаточно указанных имён и версий моделей. Суммарный объём генерации в токенах на уровне стенда не агрегировался.

3.3. Метрики оценки

Введём обозначения шкал судьи (все значения вещественные, нормированы на отрезок $[0, 10]$ баллов):

ACC (Accuracy — точность и методологическая корректность), $ACC \in [0, 10]$;

CMR (Completeness — полнота охвата требований задачи), $CMR \in [0, 10]$;

LPQ (Latent Pattern Quality — качество выявления скрытых зависимостей, инвариантов и «точек отказа»), $LPQ \in [0, 10]$;

PV (Practical Value — практическая применимость), $PV \in [0, 10]$.

Оценки выставались автоматизированным судебским протоколом на основе текста задачи, ответа модели и краткого контекста допустимых инвариантов без оценивания по буквальному совпадению с эталонным текстом.

Интегральный показатель I (в программном средстве также используется обозначение AI Score) задаётся взвешенной линейной формой по четырём

шкалам. Введём веса

$$w_{\text{CMP}} = 0,25, \quad w_{\text{ACC}} = 0,30, \quad w_{\text{LPQ}} = 0,20, \quad w_{\text{PV}} = 0,25,$$

удовлетворяющие нормировке $\sum_k w_k = 1$. Тогда

$$I = w_{\text{CMP}} \cdot \text{CMP} + w_{\text{ACC}} \cdot \text{ACC} + w_{\text{LPQ}} \cdot \text{LPQ} + w_{\text{PV}} \cdot \text{PV},$$

после чего значение отсекается на отрезок $[0, 10]$.

Веса зафиксированы в протоколе оценки до эксперимента и не подбирались по результатам стенда. Повышенный коэффициент w_{ACC} отражает приоритет методологической корректности; w_{CMP} и w_{PV} сбалансированы, чтобы совместно учитывать полноту охвата постановки и практическую применимость; w_{LPQ} задаёт отдельный вклад сигнала о скрытой структуре задачи без доминирования над остальными осями. Такая схема согласуется с общей логикой многоаспектной оценки *LLM-as-a-Judge* (модель — судья по нескольким критериям): интегральный индекс — прозрачная линейная свёртка заранее объявленных критериев, что упрощает сравнение условий при фиксированном судье [Zheng et al., 2024].

Ответ считается успешным, если I не ниже 7,0; доля успешных ответов в условии — доля успешных (безразмерная величина в $[0, 1]$, в таблицах ниже также дана в процентах).




Рис. 1: Схема конвейера: постановка T , фиксированная инструкция π (целевое или базовое условие), генерация ответа, автоматическое судейство и метрики. Узел «лог» обозначает фиксацию версий промптов, конфигураций API и файлов прогона в открытых артефактах.

4. Эксперименты и результаты

4.1. Количественные результаты

Имеется $n = 10$ парных наблюдений (по одной паре оценок на каждую из десяти задач). Инференция на таком объёме ограничена по мощности; распределение парных разностей формально не проверялось на нормальность, семейство гипотез по нескольким шкалам не корректировалось на множественность (пилот). Для сопоставимости с планируемым расширением

стенда зафиксированы H_0 : средняя парная разность для показателя равна нулю; H_1 : двусторонняя альтернатива; $\alpha = 0,05$. Основной план на будущее — парный t -тест по разностям; чувствительный анализ — знаковый ранг Вилкоксона при малых n и возможных отклонениях от нормальности. Ниже для интегрального показателя I и LPQ приведены двусторонние p -значения обоих тестов и 95 %-ные интервалы для средней парной разности (стандартный парный t -интервал, $\nu = 9$); численные отчёты воспроизводятся из JSON-артефактов `paired_pmr_vs_baseline.json` в репозитории прогнозов.

Ниже в табл. 2 сведены сводные показатели по трём испытываемым системам и доменные средние интегрального показателя I . В столбцах Δ для числовых шкал указано относительное отклонение (целевой — базовый) / базовый $\times 100$ % при ненулевом базовом уровне. Для сводных строк после среднего через знак « $\pm$ » приведено **выборочное стандартное отклонение** по десяти задачам (разброс значений от задачи к задаче); это не стандартная ошибка среднего.

Таблица 2: Сводные и доменные результаты ($n = 10$ задач на систему; в блоке доменов — среднее I по задачам домена, округление до одного десятичного).

Показатель	Qwen3 235B			DeepSeek 3.2			YandexGPT 5.1 Pro		
	ц.	б.	Δ , %	ц.	б.	Δ , %	ц.	б.	Δ , %
I	$8,3 \pm 1,2$	$6,9 \pm 0,7$	+20	$7,2 \pm 0,7$	$4,9 \pm 0,7$	+47	$4,6 \pm 0,8$	$4,3 \pm 0,3$	+7
ACC	$8,8 \pm 1,2$	$7,4 \pm 1,0$	+19	$7,8 \pm 0,8$	$5,5 \pm 1,1$	+42	$5,4 \pm 0,8$	$4,9 \pm 0,7$	+10
CMF	$7,8 \pm 1,3$	$6,5 \pm 0,7$	+20	$6,7 \pm 0,9$	$4,9 \pm 0,5$	+37	$4,4 \pm 0,8$	$4,1 \pm 0,3$	+7
LPQ	$7,8 \pm 1,7$	$5,6 \pm 0,7$	+39	$5,9 \pm 0,7$	$3,3 \pm 0,9$	+79	$3,4 \pm 0,8$	$3,1 \pm 0,3$	+10
PV	$8,8 \pm 0,9$	$7,6 \pm 0,7$	+16	$8,2 \pm 0,9$	$5,4 \pm 1,0$	+52	$4,8 \pm 1,1$	$4,7 \pm 0,5$	+4
Доля успешных, %	70	40	+75 к базе	60	0	+60 п. п.	0	0	—
<i>Доменные средние I</i>									
Инженерия ($n=3$)	8,3	6,7	+25	7,2	4,4	+66	4,6	4,3	+8
Управление ($n=3$)	8,6	6,8	+27	7,5	4,8	+56	4,9	4,1	+20
Образование ($n=2$)	8,2	7,4	+11	7,0	5,2	+34	4,6	4,2	+9
Психотерапия ($n=2$)	8,1	6,7	+20	7,1	5,5	+30	4,1	4,7	−13

Примечание. Сокращения столбцов: ц. — среднее в целевом условии; б. — в базовом; Δ — относительное изменение к базе, %; для сводных строк после « $\pm$ » — выборочное стандартное отклонение по десяти задачам. Доля успешных — при $I \geq 7,0$; для DeepSeek в ячейке Δ указан абсолютный прирост в процентных пунктах при нулевой базе. Для YandexGPT 5.1 Pro внешним судьёй служила модель Qwen3 235B.

Таблица 3: Парные разности (целевое — базовое), $n = 10$: p_t — двусторонний парный t -тест, p_W — знаковый ранг Вилкоксона; ДИ 95 % — интервал для средней разности.

Система	I			LPQ		
	p_t	p_W	ДИ 95 %	p_t	p_W	ДИ 95 %
Qwen3 235B	0,0051	0,0039	[0,78; 2,23]	0,0028	0,0156	[1,2; 3,1]
DeepSeek 3.2	< 0,0001	0,0020	[1,8; 2,9]	0,0002	0,0020	[1,8; 3,4]
YandexGPT 5.1 Pro	0,297	0,453	[−0,25; 0,76]	0,279	0,453	[−0,2; 0,8]

Интервалы для средних по десяти задачам (табл. 4) у Qwen3 235B и DeepSeek 3.2 не пересекаются между условиями ни по I , ни по LPQ, что согласуется с малыми парными p в табл. 3. У YandexGPT 5.1 Pro интервалы по I и LPQ существенно перекрываются, а p_t и p_W велики, что указывает на отсутствие устойчивого эффекта на агрегированном уровне при $n = 10$.

Расщепление по уровню сложности (по пять задач в подвыборках «промежуточный» и «повышенный») не противоречит сводной картине: для интегрального показателя у Qwen относительный прирост составляет +18%

Таблица 4: Доверительные интервалы 95 % для *средних по десяти задачам* значений I и LPQ в каждом условии (t -интервал, $\nu = 9$, полуширина $t_{0,975} s/\sqrt{10}$).

Система	I , целевое	I , базовое	LPQ, целевое	LPQ, базовое
Qwen3 235B	[7,44; 9,22]	[6,33; 7,40]	[6,47; 9,03]	[5,10; 6,10]
DeepSeek 3.2	[6,72; 7,74]	[4,33; 5,45]	[5,37; 6,43]	[2,62; 3,98]
YandexGPT 5.1 Pro	[3,95; 5,22]	[4,04; 4,54]	[2,80; 4,00]	[2,87; 3,33]

Распределения по 10 задачам: целевое (PMR) и базовое условие




Рис. 2: Ящичковые диаграммы распределений I и LPQ по десяти задачам для целевого («цель») и базового («база») условий на трёх системах. Визуально подтверждается сильнее выраженный сдвиг LPQ у Qwen3 235B и DeepSeek 3.2 и сильное перекрытие распределений I у YandexGPT 5.1 Pro.

(промежуточный) и +23% (повышенный), для LPQ — +33% и +43%; у DeepSeek для *I* — +42% и +54%, для LPQ — +67% и +93%; у YandexGPT для *I* в обеих группах +7%, для LPQ — +7% и +13%.

Наиболее выраженный относительный прирост в прогонах Qwen3 235B и DeepSeek 3.2 — по шкале LPQ (рис. 2). У YandexGPT 5.1 Pro эффекты малы, но сонаправлены по доменам, за исключением психотерапии, где целевой метод ниже базового на тринадцать процентов к базовому уровню (табл. 2).

4.2. Иллюстрация по задаче PMR-004

В качестве примера качественного сопоставления условий рассмотрим задачу PMR-004 стенда PMR-Bench (домен управления): постановка требует описать процедуру приоритизации смешанного журнала требований для B2B SaaS-продукта при заданном объёме накопленных элементов и запросе руководства зафиксировать порядок работ на квартал. В прогоне Qwen3 235B автоматический судья выставил LPQ 5,0 в базовом условии и 9,0 в целевом; интегральный показатель — 5,75 и 9,4, полнота (CMP) — 6,0 и 9,0. В базовом ответе выделяется единая универсальная шкала приоритизации для всего журнала без типовой дифференциации; целевой ответ явно ветвится по четырём классам элементов (баги, функциональность, техдолг, эксперименты), для каждого класса задаются разные критерии и формулы весов, а в блоке *P* отвергаются «универсальные» RICE/MoSCoW как несовместимые с разнородным бэклогом. В *E* фиксируются точки отказа (ошибочная классификация элемента, несопоставимость шкал между классами, сдвиг стратегии 70/20/10), а в *R* — условия пересчёта при изменении стратегии; у базы эти развилки и критерии смены процедуры остаются имплицитными. Детальные логи и формулировка постановки доступны в открытых артефактах прогона.

5. Обсуждение

5.1. Интерпретация

Согласованный рост по шкале LPQ согласуется с тем, что явная процедурная экстернализация помогает модели формулировать неочевидные зависимости и ограничения. Большой относительный выигрыш у более мощных систем может отражать лучшее заполнение процедурного каркаса содержанием, а не только соблюдение формата.

Связь с монографией Душкина Р. В., *Метакогнитивная промпт-инженерия* [Душкин, 2025]: процедурная мета-рефлексия связывает мета-уровень (процедурная прозрачность) и уровень исполнения (артефакт); целевой промпт настоящего стенда роднится с этим требованием, а пост-ответный блок — с линией ретроспективной фиксации контура в [Душкин, 2025]. Обобщение относительно канонической постановки *Метакогнитивной промпт-инженерии* [Душкин, 2025] состоит в переносе на одноходовые не диалоговые задачи и в свёртке многоагентной декомпозиции в один промпт-контракт; сужение — в отсутствии полного многоуровневого пайплайна из [Душкин, 2025] и в фокусе на измерении сравнении с базовым условием на PMR-Bench.

Отрицательное относительное изменение в психотерапии у YandexGPT 5.1 Pro поддерживает рабочую гипотезу о том, что жёсткая

трёхблочная структура может снижать гибкость ответа там, где ценятся нелинейность и тонкая настройка под контекст. Под гибкостью понимается операционализируемая совокупность признаков: доля содержания вне жёстких разделов и уровень практической ценности при неизменном внешнем судье. Проверка в следующем эксперименте: сравнить полную процедурную мета-рефлексию с облегчённым вариантом на поднаборе задач психотерапии при том же внешнем судье Qwen3 235B. В первичном анализе целесообразно зафиксировать относительное изменение практической ценности и интегрального показателя и при необходимости применить краткий экспертный чек-лист клинической уместности.

5.2. Ограничения и этика

Внутренняя валидность. Парный дизайн по задачам снижает дисперсию, связанную с различиями постановок, но не устраняет смещения судьи: в прогонах Qwen3 235B и DeepSeek 3.2 судья совпадал с исполнителем, что создаёт риск «самосогласованной» оценки формата PMR. Фиксированный порядок режимов (сначала целевой прогон всего стенда, затем базовый) не рандомизирован; возможны несезонные дрейфы API и конфигурации на стороне провайдера. Объём $n = 10$ и отсутствие поправки на множественность ограничивают устойчивость p -значений.

Внешняя валидность. Три коммерческие системы не исчерпывают рынок моделей; четыре домена и десять задач не покрывают все прикладные форматы (мультиходовые диалоги, инструментальные агенты, доменно-специфичные регламенты). Перенос на другие языки постановок, другие судьи и другие веса w_k требует отдельной проверки.

Этика и снижение рисков. Постановки стенда — учебно-прикладные сценарии без идентифицируемых персональных данных; дословное цитирование ответов моделей в публичном тексте не приводится. Для возможных будущих материалов с реальными диалогами предполагаются: анонимизация и удаление идентификаторов, согласие участников при сборе данных, регламент доступа к полным логам, а для клинически чувствительных доменов — независимая экспертная проверка уместности.

План независимой экспертизы для психотерапевтических постановок (при расширении стенда) предполагает панель из двух–трёх лицензированных клинических психологов или врачей-психиатров с опытом КПТ/АСТ, слепую оценку по короткому чек-листу (клиническая уместность, безопасность, соответствие согласованному протоколу) относительно деидентифицированных текстов постановки и ответа, разрешение расхождений на консенсусной встрече и отдельное согласование с автоматическими оценками судьи. Формат — полуструктурированная форма в веб-опроснике или таблице; сроки и размер панели уточняются при подаче гранта или партнёрства с клинической организацией.

5.3. Направления развития

Перспективными шагами представляются расширение набора задач, привлечение единого внешнего судьи для всех испытуемых систем, экспертная кросс-проверка автоматических оценок и сопоставление предлагаемой техники

с альтернативными схемами промптинга. Отдельно целесообразна проверка гипотезы о гибкости в психотерапии по схеме, изложенной в п. 5.1.

6. Заключение

Вклад статьи заключается в следующем:

1. Предложено операциональное описание техники процедурной мета-рефлексии (до решения, в процессе, после решения), согласованной с линией монографии Душкина [Душкин, 2025] и реализованной в одноходовой постановке открытого стенда PMR-Bench.
2. Проведено парное сравнительное экспериментальное исследование целевого промпта и структурированного базового условия; на Qwen3 235B и DeepSeek 3.2 зафиксированы устойчивые улучшения по осям полноты (CMP), точности (ACC), глубины выявления скрытых зависимостей (LPQ) и практической ценности (PV), а также по интегральному показателю в сочетании со значимыми парными тестами при $n = 10$ (табл. 3). На YandexGPT 5.1 Pro относительные приросты по агрегатам малы, парные p -значения велики (раздел 4).
3. Продемонстрирована применимость метода на стенде из десяти прикладных постановок в доменах инженерии, управления, образования и психотерапии.
4. Для воспроизводимости представлены открытый исходный код программного средства, протокол автоматического судейства и фиксация конфигураций прогонов; параметры промптинга и версии инструкций доступны в репозитории проекта (в публикацию полные тексты промптов не включались).

Таким образом, цель и задачи, сформулированные во введении, выполнены в пилотном масштабе: операциональный контракт и схема конвейера (рис. 1) изложены в разделе 3; количественное сравнение, доверительные интервалы и парные проверки для I и LPQ — в разделе 4 (табл. 2–4, табл. 3, рис. 2). Рабочая гипотеза о приросте I и LPQ подтверждается для Qwen3 235B и DeepSeek 3.2 и не подтверждается для YandexGPT 5.1 Pro на уровне агрегированных парных статистик при $n = 10$; гипотеза о доминировании эффекта по LPQ согласуется с данными двух более мощных систем. Ограничения дизайна и обобщаемости сведены в разделе 5.

На стенде из десяти задач при парном дизайне показано, что целевой промпт даёт положительное относительное изменение интегрального показателя и осей качества у трёх различных испытуемых систем; наиболее выражен рост по шкале LPQ. Практическое использование — как методический шаблон для сценариев, где важны воспроизводимость и аудит рассуждения, и как основа для расширяемого открытого стенда.

Благодарности

Вычислительная часть работы, представленная в статье, выполнялась с использованием платформы Yandex Cloud, в частности сервисов доступа к

облачным моделям генерации текста (включая API семейства YandexGPT) и сопутствующих облачных ресурсов для запуска экспериментального конвейера и обращений к внешним API моделей. Исследование проводилось при грантовой поддержке Центра Yandex Cloud по технологиям для общества. Авторы выражают благодарность команде Yandex AI Studio за инструментальную и организационную поддержку.

Список литературы

При подаче в журнал, ориентирующийся на ГОСТ Р 7.0.5 / ГОСТ Р 7.0.100, библиографические описания ниже могут потребовать перестановки элементов, обозначения года издания электронного ресурса и замены разделителей; монография [Душкин, 2025] сохраняется в тексте и в списке в явном виде.

1. Anderson J. R. The Architecture of Cognition. — Cambridge, MA : Harvard University Press, 1983. — 345 p.
2. Wei J., Wang X., Schuurmans D. et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models // NeurIPS 2022: Proceedings of the 36th International Conference on Neural Information Processing Systems. — 2022. — Vol. 35. — P. 24824–24837.
3. Yao S., Yu D., Zhao J. et al. Tree of Thoughts: Deliberate Problem Solving with Large Language Models // Advances in Neural Information Processing Systems. — 2024. — Vol. 36. — P. 11809–11822.
4. Flavell J. H. Metacognition and cognitive monitoring: a new area of cognitive-developmental inquiry // American Psychologist. — 1979. — Vol. 34, № 10. — P. 906–911.
5. Wang Y., Zhao Y. Metacognitive Prompting Improves Understanding in Large Language Models // Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. — 2024. — P. 1234–1245.
6. Zheng L., Chiang W.-L., Ying J. et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena // Advances in Neural Information Processing Systems. — 2024. — Vol. 36. — P. 46595–46626.
7. Душкин Р. В. Метакогнитивная промпт-инженерия. — Москва : ДМК Пресс, 2025. — 238 с.